

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH – VIỆT NAM



ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN

HỆ THỐNG TÌM KIẾM, PHÁT HIỆN VÀ NGĂN NGỪA XÂM NHẬP

GAN-based imbalanced data intrusion detection system

GIẢNG VIÊN HƯỚNG DẪN: ĐỖ HOÀNG HIỂN

NT204.N21.ATCL – VN

NHÓM 5:

TRƯƠNG THỊ HOÀNG HẢO - 20520191

NGUYỄN ĐỨC TRUNG - 20520956

LÊ QUANG MINH - 20520245

NGUYỄN VIỆT HOÀNG – 20520189

MỤC LỤC

I. GIỚI THIỆU.....	3
II. THIẾT KẾ VÀ CÀI ĐẶT.....	3
2.1 Thiết kế	3
2.2 Dataset.....	4
2.3 GAN.....	5
2.4 CTGAN	5
2.5 Rare resampling	6
2.6 Classification	6
III. KẾT QUẢ.....	7
IV. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	10
V. TÀI LIỆU THAM KHẢO	11
VI. PHÂN CHIA CÔNG VIỆC	11

I. GIỚI THIỆU

Với sự phát triển của ngày càng nhanh của Công nghệ thông tin thì việc an toàn bảo mật mạng cũng ngày càng trở nên phức tạp. Các nhu cầu bảo vệ về thông tin các nhân cũng, cũng như các vụ tấn công mạng ngày càng gia tăng. Do đó các Hệ thống tìm kiếm, phát hiện và ngăn ngừa xâm nhập đã trở thành một phần không thể thiếu trong máy tính và an toàn mạng.

Phát hiện xâm nhập là một biện pháp bảo mật giúp bảo vệ máy tính và hệ thống mạng khỏi khả năng khai thác. Hệ thống phát hiện xâm nhập phát hiện các bất thường thông qua nhiều phương pháp, trong đó bao gồm dựa trên các signature-based, bằng việc so sánh với các mẫu tấn công đã được cấu hình từ trước. Ngoài ra ta còn có các phương pháp anomaly-based và hybrid-based từ đó giúp gia tăng hiệu quả trong việc phát hiện các ngoại lệ

Trong đó việc ứng dụng Machine Learning/Deep Learning với IDS cũng ngày càng được phổ biến bởi độ chính xác cao cũng như có thể tự động phát hiện các loại hình tấn công chưa được phát hiện. Việc ứng dụng Deep Learning vào các mô hình phân loại IDS cần sử dụng một lượng dữ liệu lớn, nên vì thế đối với các tập dữ liệu mất cân bằng, độ chính xác của mô hình sẽ giảm đáng kể. Đã có nhiều nghiên cứu trong việc giải quyết vấn đề mất cân bằng dữ liệu tuy nhiên phần lớn gặp điểm yếu trong việc mất dữ liệu hoặc overfitting.


Ở đây nhóm đề xuất sử dụng phương pháp Generative Adversarial Network (GAN), mô hình học không giám sát để tạo ra một tập dữ liệu ảo tương tự với tập dữ liệu ban đầu và sử dụng mô hình Random Forest (RF) để đánh giá kết quả của mô hình so với việc có và không sử dụng GAN.

II. THIẾT KẾ VÀ CÀI ĐẶT

2.1 Thiết kế

Mô hình của bài báo được thể hiện trong hình 1. Sau khi chuẩn hóa dataset, tập train và tập test chia lần lượt thành 60 và 40. Tập train được điều chỉnh sau khi rare class của tập train đã được học bởi GAN và tạo ra những mẫu mới.

Tập train và tập dữ liệu ảo do mô hình GAN tạo ra sẽ được gộp lại thành một và đưa vào mô hình học máy RF để huấn luyện mô hình multilabel phát hiện tấn công. Mô hình sẽ được kiểm chứng bởi tập test.




Hình 1: Mô hình đề xuất

2.2 Dataset

Tập dữ liệu được sử dụng cho mô hình đề xuất là CICIDS 2017. Tập dữ liệu này bao gồm các traffic bình thường và 12 loại tấn công. Tỷ lệ dữ liệu tương tự như mạng trong thực tế, nơi mà các dữ liệu bình thường chiếm hơn 80% và có ít hơn 0.1% các class thiểu số như Infiltration, web attacks và Heartbleed attacks.

2.3 GAN


GAN là mô hình sinh hồi quy được phát minh bởi Ian Goodfellow ở NIPS năm 2014. Về cơ bản, một mạng neuron gọi là G sẽ tạo ra dữ liệu mới tương đồng. Trong khi đó, mạng neuron D sẽ đánh giá tính xác thực của dữ liệu. G sẽ tạo ra một image mới để đánh lừa D. Mục đích của D là xác định image tạo ra từ G là giả. Điều này được minh họa trong hình 2.



Hình 2. Cấu trúc của GAN

2.4 CTGAN

Conditional GAN (CTGAN) là một phương pháp dựa trên GAN (Generative Adversarial Network) để mô hình hóa phân phối dữ liệu bảng và tạo ra mẫu từ phân phối đó. Mô hình này sử dụng phương pháp chuẩn hóa theo chế độ để xử lý sự phân phối không Gaussian và đa chế độ trong dữ liệu bảng. CTGAN thiết kế một bộ sinh có điều kiện và sử dụng huấn luyện bằng cách lấy mẫu để xử lý các cột rời rạc không cân bằng trong dữ liệu bảng. Mô hình CTGAN sử dụng mạng fully-connected và các kỹ thuật mới nhất để huấn luyện một mô hình chất lượng cao.



Hình 3. Mô hình CTGAN

Mô hình CTGAN sử dụng bộ sinh có điều kiện để tạo ra các hàng tổng hợp dựa trên một trong các cột rời rạc trong dữ liệu.

Với huấn luyện bằng cách lấy mẫu, dữ liệu điều kiện và dữ liệu huấn luyện được lấy mẫu theo tần suất log của mỗi danh mục. Điều này giúp CTGAN khám phá đồng đều tất cả các giá trị rời rạc có thể có.

CTGAN là một phương pháp ưu việt hơn GAN trong việc mô hình hóa và tổng hợp dữ liệu bảng/tabular. Với khả năng xử lý các biến rời rạc, phân phối phức tạp và đa chế độ, CTGAN cho phép tạo ra dữ liệu tổng hợp chất lượng cao và đa dạng hơn

2.5 Rare resampling

Sử dụng mô hình GAN, nghiên cứu này đã tạo ra 10.000 dữ liệu Bot, Infiltration và Heartbleed bổ sung, đây là các lớp hiếm gặp chỉ chiếm ít hơn 0,1% của bộ dữ liệu CICIDS2017. Batch_size là 500 và 300 epochs. Trong đó, Batch_Size là số lượng dữ liệu được học một lần còn Epoch hoàn thành việc học một lần cho toàn bộ bộ dữ liệu và kết quả tốt nhất đạt được khi epoch là 300.

2.6 Classification

Trong nghiên cứu này, mô hình RF, một thuật toán học máy điển hình, dùng để phân loại dựa trên dữ liệu mẫu tái tạo. Một ví dụ về ensemble learning là RF, mô hình này học từ nhiều mô hình học máy và dùng mô hình dự đoán để dự đoán giá trị tốt hơn là 1 model. RF

là một thuật toán mà tạo ra nhiều cây quyết định (decision trees (DT)) và dự đoán lớp được chọn nhiều nhất giữa những giá trị được dự đoán trong mỗi cây.

Không dễ dàng để tạo ra DT bởi vì nó phụ thuộc vào tập train. Đồng thời, vì phương pháp tiếp cận theo bậc, nếu có lỗi xảy ra trong quá trình phân loại thì phương pháp này sẽ không phù hợp cho việc phân loại trong môi trường mạng do tính chất của lỗi sẽ lan truyền liên tục ở các bước tiếp theo.

Trong thực nghiệm thì phân loại RF sử dụng thư viện của sklearn, thiết lập các siêu tham số `Random_state = 1` và `n_estimators = 100`. `Random_state` sẽ cố định ngẫu nhiên hóa việc chọn biến để đạt được kết quả giống nhau trong các thí nghiệm, `n_estimators` chỉ số lượng DT.

III. KẾT QUẢ

Ở đây nhóm đánh giá kết quả của mô hình RF sau khi train dựa trên 4 tiêu chí được thể hiện trong hình 4. Kết quả của từng tiêu chí được thể hiện ở bảng 1.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Hình 4: Các tiêu chí để đánh giá mô hình RF


Model	Accuracy (%)	Precision	Recall	F1-score
RF – SMOTE & RandomOversampling (1)	99.85	0.9986	0.9985	0.9986
RF - CTGAN (2)	99.87	0.9986	0.9987	0.9986

Bảng 1: Kết quả của hai mô hình (1) và (2)


	Flow Type
0	BENIGN
1	DDoS Hulk
2	DdoS Golden Eye
3	DoS Slowloris
4	DoS Slowhttptest
5	DDoS
6	PortScan
7	FTP-Patator
8	SSH-Patator
9	Web Attack
10	Bot
11	Infiltration
12	Heartbleed

Bảng 2: Bảng đánh số cho từng loại tấn công trong tập CICIDS2017

Kết quả phân loại cụ thể của từng label (được đánh số ở bảng 2) sẽ được thể hiện lần lượt qua confusion matrix ở hình 5 và hình 6 khi sử dụng model (1) và model (2). Số mẫu phân loại không đúng của model (1) là 1588 mẫu còn model (2) là 1458 mẫu.



Hình 5: Confusion matrix của model RF-SMOTE



Hình 6: Confusion matrix của model RF-CTGAN

Dựa vào kết quả thu được, mô hình sử dụng CTGAN để tạo mẫu ảo có khả năng nhận diện hai loại tấn công là “Bot” và “Infiltration” còn thấp. Lượng dữ liệu do hai loại tấn công này cung cấp trong tập train không đủ để thỏa mãn yêu cầu của mô hình CTGAN. Vì thế, chất lượng của các mẫu cho cả ba loại tấn công tạo ra bằng CTGAN chỉ đạt mức 76.29% so với các mẫu thật. Tuy nhiên, mô hình (2) đã thu được kết quả tốt hơn về mặt tổng quan và cũng không làm mất dữ liệu như khi sử dụng kỹ thuật Random Undersampling kết hợp với SMOTE ở mô hình (1).

IV. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Nghiên cứu này sử dụng mô hình GAN để tái tạo mẫu của một vài lớp thiểu số nhằm tái tạo chúng với độ chính xác cao. Số lượng dữ liệu của các lớp hiếm Bot, Infiltration và Heartbleed được huấn luyện bằng GAN và tăng dữ liệu của mỗi lớp lên 10000 mẫu để đánh giá hiệu năng phân loại. Kết quả thử nghiệm cho thấy hiệu năng phân loại với Random

Forest sau khi tái tạo mẫu bằng GAN tốt hơn so với mô hình Random Forest kết hợp với SMOTE và Random Undersampling.

Mặc dù SMOTE và GAN có tương đồng trong việc tạo ra dữ liệu nhưng SMOTE có vấn đề về các lớp chồng lên nhau và bị nhiễu. Do đó, kết quả của mô hình GAN (tái tạo lại lớp hiếm và so sánh chính xác các thuộc tính) hiệu quả hơn trong việc xử lý dữ liệu mất cân bằng, giảm thiểu mất mát trong dữ liệu.

Trong tương lai, IDS có thể được tăng cường, tăng tốc độ bằng cách thêm mô hình autoencoder nhằm nén các thuộc tính dữ liệu xuống level thấp trước khi tái tạo mẫu với GAN, hay cải thiện độ chính xác của các mẫu được tạo ra bởi GAN để tăng khả năng nhận diện của mô hình.

V. TÀI LIỆU THAM KHẢO

- [1] L. Xu, M. Skoularidou, A. Cuesta-Infante, and K. Veeramachaneni, “Modeling tabular data using conditional gan. arxiv 2019,” arXiv preprint arXiv:1907.00503, vol. 1, 1907.
- [2] J. Lee and K. Park, “Gan-based imbalanced data intrusion detection system,” Personal and Ubiquitous Computing, vol. 25, pp. 121–128, 2021.

VI. PHÂN CHIA CÔNG VIỆC

TRƯƠNG THỊ HOÀNG HẢO - 20520191	Tạo dữ liệu bằng CTGAN, dựng mô hình (2).
NGUYỄN ĐỨC TRUNG - 20520956	Feature engineering tập dữ liệu, dựng mô hình (1).
LÊ QUANG MINH - 20520245	Tìm hiểu về CTGAN, viết báo cáo
NGUYỄN VIỆT HOÀNG - 20520189	Tìm hiểu về CTGAN, viết báo cáo

-----HẾT-----

Xin cảm ơn!