

Phương Pháp Phát Sinh Dữ Liệu Tấn Công Đánh Lừa IDS Học Máy Dựa Trên Mạng Sinh Đối Kháng

Cao Phan Xuân Quý, Đặng Hồng Quang, Phan Thế Duy, Đỗ Thị Thu Hiền, Phạm Văn Hậu

¹Phòng Thí nghiệm An toàn Thông tin, Trường Đại học Công Nghệ Thông Tin

²Đại học Quốc gia Thành phố Hồ Chí Minh

Email: {17520953, 17520944}@gm.uit.edu.vn, {duypt, hiendtt, haupv}@uit.edu.vn

Abstract—Trình phát hiện xâm nhập mạng (Network IDS) được xây dựng để phát hiện và cảnh báo khi hệ thống bị tấn công, từ đó có thể đưa ra các phản ứng phù hợp. Với sự bùng nổ của dữ liệu, các phương pháp học máy đã bắt đầu được áp dụng trong một số IDS khác nhau. Tuy nhiên, các hệ thống này cho tỉ lệ báo động giả cao cũng như dễ bị đánh lừa bởi các cuộc tấn công tinh vi như tấn công đối kháng. Vì vậy, cần phải liên tục kiểm tra và cải tiến các hệ thống này bằng cách mô phỏng các đột biến tấn công mạng trong thế giới thực. Trong nghiên cứu này, chúng tôi thiết kế và giới thiệu DIGFuPAS (Deceive IDS with GAN and Function-Preserving on Adversarial Samples), một bộ khung sinh ra dữ liệu các cuộc tấn công mạng có khả năng vượt qua được các hệ thống IDS, kể cả IDS học máy. Dựa trên Mô hình sinh đối kháng (GAN), DIGFuPAS tạo ra các luồng dữ liệu độc hại đột biến từ lưu lượng tấn công thực khiến IDS không thể phát hiện được. Mô hình được thực nghiệm trên bộ dữ liệu công khai CICIDS2017. Chúng tôi chỉ sửa đổi các thuộc tính phi đặc trưng (nonfunctional features) tương ứng của các loại tấn công để đảm bảo khả năng hoạt động của hành vi xâm nhập. Hiệu quả của mô hình được đánh giá thông qua độ chính xác và tỉ lệ phát hiện tấn công của IDS đối với lưu lượng tấn công thông thường và lưu lượng tấn công đối kháng. Phương pháp này có thể được sử dụng cho việc kiểm tra, đánh giá khả năng phát hiện của IDS một cách liên tục một khi DIGFuPAS được tích hợp dưới dạng pipeline kiểm tra tự động tính bền vững cho các sản phẩm IDS phổ biến mã nguồn mở hoặc IDS thương mại.

Keywords— IDS, Machine Learning Based IDS, Generative Adversarial Networks, Adversarial Attacks.

I. GIỚI THIỆU

Với sự phát triển ngày càng đa dạng và phức tạp của các mối đe dọa bảo mật trên Internet, hệ thống phát hiện xâm nhập (IDS) trở thành công cụ thiết yếu để phát hiện các cuộc tấn công mạng và hệ thống. IDS giám sát lưu lượng mạng và đưa ra các cảnh báo nếu xác định được những lưu lượng không an toàn. Dựa trên cách phát hiện tấn công, IDS được chia thành 2 loại chính là Signature-based IDS và Anomaly-based IDS. Signature Based IDS nhận biết tấn công dựa trên các dấu hiệu đặc trưng, được

quản trị viên cài đặt vào hệ thống dưới dạng các bộ quy định (rules). Tuy nhiên, nhược điểm của hệ thống loại này là không thể phát hiện các cuộc tấn công mới. Trong khi đó, Anomaly-based IDS vốn sử dụng các thuật toán học máy – hay Machine Learning Based IDS (ML IDS) có thể khắc phục nhược điểm này do hoạt động dựa trên nguyên lý phân loại dữ liệu. Khi đề cập đến vấn đề phân loại, các thuật toán học máy đã được áp dụng rộng rãi trong thực tế trên nhiều lĩnh vực khác nhau như phân loại ảnh nói riêng và dữ liệu nói chung, trong đó hướng tiếp cận của IDS dựa trên học máy cũng đã đạt được những kết quả tốt. Nhiều thuật toán học máy khác nhau đã được dùng để phân loại dữ liệu, trong đó có thể kể đến K-Nearest Neighbor, Support Vector Machine, Decision Tree, v.v. [1]. Trong những năm gần đây, các thuật toán học sâu phát triển nhanh chóng đã thúc đẩy sự phát triển hơn nữa trong vấn đề phát hiện xâm nhập, như Mạng thần kinh kết hợp (CNN), Mạng thần kinh hồi quy (RNN), Bộ mã hóa tự động, v.v. [2]. Các thuật toán này giúp cải thiện độ chính xác và đơn giản hóa việc phát hiện xâm nhập [3].

Tuy nhiên, hệ thống phát hiện xâm nhập dần dần bộc lộ điểm yếu trước các lưu lượng mạng đối kháng: các lưu lượng mạng gần giống với lưu lượng gốc nhưng lại được phân loại không chính xác [4]. Những kẻ tấn công có thể cố gắng đánh lừa các hệ thống IDS, khiến chúng phân loại sai bằng cách sử dụng các bản ghi lưu lượng độc hại đối kháng. Để sinh ra các lưu lượng mạng đối kháng như vậy, các mô hình sinh đối kháng (Generative Adversarial Networks - GAN) chính là phương pháp được lựa chọn tiềm năng. Goodfellow và cộng sự đã giới thiệu GAN, một khuôn khổ để huấn luyện các mô hình tạo sinh đối kháng [5], với ý tưởng chính là hai mạng thần kinh nhân tạo, mạng tạo sinh (Generator) và mạng phân biệt (Discriminator) cùng chơi trò chơi minimax để hội tụ thành một giải pháp tối ưu [6]. Không chỉ thể hiện bước tiến hiện đại trong việc tạo ra hình ảnh, âm thanh và văn bản [7] [8] [9], GAN cũng đã được chú trọng trong lĩnh vực bảo mật thông tin trong thời gian gần đây. Các nghiên cứu hiện tại đã sử dụng GAN để cải thiện khả năng phát hiện phần mềm độc hại hoặc tạo ra chính

các mẫu phần mềm độc hại đối kháng, từ đó khiến các cuộc tấn công ngày càng đe dọa và nghiêm trọng [10] [11]. Tuy vậy, hiện nay những nghiên cứu về GAN được sử dụng trong IDS vẫn còn rất hạn chế.

Một nghiên cứu của Grosse và các cộng sự đã đề xuất áp dụng thuật toán dựa trên đạo hàm chuyển tiếp các mạng nơ-ron bị tấn công để tạo ra các phần mềm độc hại đối kháng trên Android với chức năng độc hại được bảo toàn [13]. Một công trình khác sử dụng thuật toán học tăng cường với một tập hợp các hoạt động bảo toàn chức năng để tạo ra các phần mềm độc hại đối kháng [14]. Trong khi đó, Rosenberg đã tạo ra các ví dụ điển hình về đối kháng khi kết hợp chuỗi lệnh gọi API và các tính năng tĩnh với bộ khung tạo tấn công end-to-end [15]. Trong nghiên cứu của mình, Al-Dujaili đã trình bày 4 phương pháp để tạo các phần mềm đối kháng được mã hóa nhị phân với chức năng độc hại được bảo tồn với việc sử dụng SLEIPNIR để đào tạo các bộ phát hiện mạnh mẽ [16]. Bên cạnh đó, thư rác đối kháng cũng nhận được sự quan tâm khi Zhou đã tạo ra thư rác bằng mô hình sinh đối kháng SVM và từ đó nghiên cứu cách tạo ra một bộ lọc thư rác mạnh mẽ hơn [17]. Cùng với việc công nghệ đối kháng đã được áp dụng rộng rãi trong việc phát hiện phần mềm độc hại, đã có những công bố nghiên cứu việc tạo ra lưu lượng truy cập độc hại đối kháng chống lại IDS. Một nghiên cứu của James và các cộng sự cũng đã đề xuất một phương pháp đánh lừa IDS học máy trên các mẫu tấn công DoS đối kháng, bằng cách thay đổi một số thuộc tính mạng [18]. Tuy nhiên, mô hình của các tác giả hoạt động chủ yếu dựa trên các thuộc tính cụ thể của tấn công DoS nên khó có khả năng mở rộng.

Ở một hướng tiếp cận khác, GAN cũng đã được ứng dụng rộng rãi trong việc tạo ra các mẫu tấn công đối kháng trong bảo mật thông tin. Hu đã đề xuất một bộ khung GAN để tạo ra các phần mềm độc hại cho các cuộc tấn công hộp đen [11]. Hu cũng tận dụng một mô hình mới để tạo một số chuỗi API đối kháng sẽ được chèn vào chuỗi API ban đầu của phần mềm để hình thành các cuộc tấn công, nhằm mục đích vượt qua các hệ thống phát hiện Mạng thần kinh hồi quy (RNN) [19]. Không chỉ vậy, khả năng tạo ra các mẫu đối kháng của GAN cũng đã được tận dụng trong một số nghiên cứu nhằm qua mặt IDS. Điển hình có thể kể đến nghiên cứu [20] đề xuất cơ chế tạo ra các lưu lượng tấn công đối kháng có thể đánh lừa các IDS máy học. Mô hình được thiết kế dựa trên kiến trúc WGAN để cải thiện khả năng hội tụ trong quá trình huấn luyện. Bộ sinh trong công trình này chọn thay đổi một số thuộc tính của lưu lượng mạng để tạo mẫu đối kháng, trong khi bộ phân biệt tìm cách bắt chước hoạt động của IDS máy học nhằm hỗ trợ gửi phản hồi cho bộ sinh. Tuy vậy, một nghiên cứu của Usama và cộng sự [21] đã chỉ ra vấn đề tồn tại trong IDSGAN khi thay đổi một số thuộc tính chức năng của lưu lượng mạng. IDSGAN đã vi phạm yêu cầu giữ nguyên tính hợp lệ của lưu lượng mẫu đối kháng. Nhóm tác giả nghiên cứu sau đó đưa ra đề xuất cơ chế đảm bảo giữ nguyên các thuộc tính chức năng trong quá trình tạo

mẫu đối kháng, khi bộ sinh chỉ thực hiện thay đổi trên nhóm các thuộc tính phi đặc trưng. Nhưng giải pháp lại đề xuất sử dụng GAN cơ bản, vốn có thể đối mặt với vấn đề khó hội tụ trong quá trình huấn luyện.

Bên cạnh đó, dữ liệu đầu vào trong hướng tiếp cận sử dụng GAN cũng là một vấn đề cần quan tâm của các nghiên cứu. Một nghiên cứu của Msika và các cộng sự đã chứng minh kích thước và độ đa dạng của đầu vào có thể ảnh hưởng đến hiệu suất của GAN [22]. Nghiên cứu này sử dụng chính các thuộc tính phi chức năng làm đầu vào để tạo mẫu đối kháng, điều này có thể làm giảm tính đa dạng của dữ liệu được tạo so với việc sử dụng nhiều như công trình IDSGAN. Mặt khác, tập dữ liệu KDD99 sử dụng trong công trình của Usama tuy phổ biến trong việc kiểm tra hoạt động của IDS nhưng có thể chứa những bản ghi lưu lượng đã cũ, khó phát hiện các tấn công mới hiện nay. IDSGAN sử dụng phiên bản cải tiến của KDD99 là NSL-KDD, tuy vậy về cơ bản hai tập dữ liệu này vẫn gặp vấn đề tương tự.

Từ những bất cập trên, chúng tôi đề xuất và xây dựng DIGFuPAS, một bộ khung dựa trên mô hình sinh đối kháng GAN, nhằm mục tiêu trực tiếp vào các hệ thống IDS, kể cả IDS có sử dụng công nghệ phát hiện dựa trên học máy. Mục tiêu của bộ khung DIGFuPAS là tạo ra các bản ghi lưu lượng độc hại đối kháng có thể đánh lừa cũng như tránh được sự phát hiện của các hệ thống phòng thủ. Hơn nữa, DIGFuPAS bảo toàn được các thuộc tính chức năng từ đó đảm bảo tính hợp lệ của lưu lượng đối kháng. Chúng tôi dùng một IDS hộp đen sử dụng các thuật toán học máy để mô phỏng chính xác cách hệ thống phát hiện xâm nhập vận hành trong thế giới thực khi kẻ tấn công không rõ cấu trúc bên trong của nó. Chúng tôi thiết kế và cải tiến bộ sinh và bộ phân biệt dựa trên cơ sở Wasserstein GAN (WGAN) vì các đặc tính ưu việt của nó [12]. Bộ sinh tạo ra các cuộc tấn công với lưu lượng truy cập độc hại đối kháng. Bộ phân biệt bắt chước IDS hộp đen và cung cấp phản hồi cho việc huấn luyện bộ sinh. Sau khi được huấn luyện kẻ tấn công có thể sử dụng các lưu lượng đối kháng được sinh ra từ bộ sinh để thực hiện tấn công vượt qua IDS.

Tóm lại, trong bài báo này, chúng tôi có những đóng góp chính như sau:

- Chúng tôi thiết kế DIGFuPAS, một bộ khung dựa trên GAN để tạo ra các lưu lượng truy cập độc hại đối kháng tấn công hệ thống phát hiện xâm nhập IDS. Lưu lượng tấn công đối kháng được sinh ra sẽ không bị mất hiệu lực chức năng tấn công.
- Để mô phỏng chính xác các cuộc tấn công nhắm vào IDS trong thế giới thực, các cuộc tấn công đối kháng được thực hiện trên IDS hộp đen có sử dụng các thuật toán học máy.
- DIGFuPAS thể hiện hiệu suất tốt trong các thử nghiệm với tỷ lệ phát hiện đối với các lưu lượng đối kháng giảm đáng kể trước các cuộc tấn công khác nhau, có nghĩa là hầu hết các cuộc tấn công đối kháng có thể đánh lừa và vượt qua được sự phát hiện của IDS hộp đen.

- Đề tổng kết, chúng tôi đề xuất trường hợp sử dụng và đưa ra các thảo luận về mức độ ảnh hưởng của mô hình sinh đối kháng GAN trước các hệ thống cảnh báo tấn công như IDS hiện nay.

Phần còn lại của bài báo được tổ chức như sau: trong phần II, chúng tôi miêu tả mô hình đề xuất bao gồm việc chọn và xử lý dữ liệu, cũng như quá trình xây dựng và huấn luyện kiến trúc DIGFuPAS. Trong phần III, chúng tôi nêu lên phương pháp đánh giá hiệu năng của hệ thống. Phần IV cung cấp các kết quả mô phỏng và phân tích lý thuyết. Cuối cùng, trong phần V, chúng tôi đi đến kết luận về giá trị của đề tài trong nghiên cứu và trong thực tế, cũng như khả năng phát triển trong tương lai.

II. MÔ HÌNH HỆ THỐNG

Chúng tôi thiết kế DIGFuPAS gồm 3 thành phần chính: Bộ sinh (Generator – G), bộ phân biệt (Discriminator – D) và IDS hộp đen (Blackbox IDS – B-IDS). Bộ khung này được huấn luyện để có khả năng tạo ra dữ liệu tấn công đối kháng từ mẫu tấn công ban đầu dựa trên Wassertein GAN - một biến thể khắc phục vấn đề khó đào tạo bộ sinh và khả năng hội tụ trong mô hình GAN tiêu chuẩn. Mục tiêu trong phạm vi bài báo này là B-IDS không có khả năng nhận diện, phát hiện các mẫu tấn công được tạo mới từ DIGFuPAS.

A. Xử lý dữ liệu

Tại thời điểm thực hiện nghiên cứu, bộ dữ liệu CICIDS thu thập bởi Viện An ninh mạng Canada (Canadian Institute for Cybersecurity) đã có phiên bản mới nhất là CICIDS2018. Tuy nhiên, do kích thước bộ dữ liệu lớn và hạn chế về tài nguyên phần cứng như đã đề cập, trong phạm vi nghiên cứu này chúng tôi chỉ sử dụng bộ dữ liệu CICIDS2017. Bộ dữ liệu này bao gồm lưu lượng mạng lành tính và lưu lượng mạng trước các cuộc tấn công phổ biến, được cung cấp dưới dạng các tệp PCAP chứa các gói tin mạng trong quá trình thu thập dữ liệu và các tệp CSV chứa thông tin thống kê lưu lượng mạng đã được dán nhãn. Chúng tôi sử dụng dữ liệu từ 4 trong số 8 tệp CSV đã được cung cấp để mô phỏng các cuộc tấn công. **Bảng 1** trình bày một số thông tin cơ bản về những tệp dữ liệu được sử dụng trong nghiên cứu này. Dữ liệu trong mỗi tệp được trình bày dưới dạng bảng có nhiều cột thuộc tính (tabular) và cần được tiền xử lý trước khi có thể sử dụng. Đầu tiên, chúng tôi loại bỏ một số cột thuộc tính không ảnh hưởng đến quá trình huấn luyện là các cột thuộc tính chỉ chứa duy nhất một giá trị. Ngoài ra, các cột thuộc tính thuộc về chi tiết của luồng lưu lượng thể hiện thông tin hệ thống sử dụng để xây dựng bộ dữ liệu cũng bị loại bỏ, cụ thể là Flow ID, Source IP, Source Port, Destination IP, Destination Port, Protocol, Timestamp. Tiếp theo, chúng tôi loại bỏ các bản ghi chưa hoàn thiện là các hàng có chứa giá trị NaN (Not a Number – không xác định). Sau đó, mỗi giá trị trong tệp dữ liệu được chuẩn hoá về khoảng [0, 1] bằng hàm Min-Max theo **công thức (1)**, với x_{min} , x_{max} lần lượt là giá trị nhỏ nhất và giá trị lớn nhất của cột thuộc tính. Cuối cùng,

Bảng 1. Thông tin về các tệp dữ liệu được sử dụng

Loại tấn công	Tập dữ liệu	Nhãn
DOS	Wednesday- workingHours. pcap_ISCX.csv	BENIGN, DoS slowloris, DoS Slowhttptest, DoS Hulk, DoS GoldenEye
DDOS	Friday- WorkingHours- Afternoon-DDos. pcap_ISCX.csv	BENIGN, DDoS
Bruteforce	Tuesday- WorkingHours. pcap_ISCX.csv	BENIGN, FTP- Patator, SSH- Patator
Infiltration	Thursday- WorkingHours- Afternoon- Infiltration. pcap_ISCX.csv	BENIGN, Infiltration


để thuận tiện cho quá trình huấn luyện, đối với từng loại tấn công, các nhãn mang giá trị BENIGN sẽ được thay đổi thành 0, các nhãn còn lại biểu thị chi tiết về kiểu tấn công đối với loại tấn công có nhiều kiểu (DOS, Bruteforce) sẽ được thay đổi thành 1.

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (1)$$

Sau quá trình tiền xử lý, từng tệp dữ liệu được chia thành 3 tệp con với tỉ lệ 4:4:2, mỗi tệp sẽ chứa N thuộc tính tùy thuộc vào từng loại tấn công. Trong đó, 2 tệp chiếm tỉ lệ cao hơn gọi là tệp train1 và train2 được sử dụng để huấn luyện IDS hộp đen và GAN, tệp còn lại gọi là test dùng để kiểm tra kết quả huấn luyện.

B. Xây dựng kiến trúc DIGFuPAS

Bộ sinh và bộ phân biệt được xây dựng dựa trên mô hình Wassertein-GAN để tăng tính ổn định của quá trình huấn luyện. Trong đó, bộ sinh nhận đầu vào là các thuộc tính phi chức năng của các bản ghi tấn công kèm theo nhiễu để sinh ra các bản ghi lưu lượng đối kháng. Các bản ghi này được đưa đến cho B-IDS gán nhãn, sau đó chuyển kết quả gán nhãn đến bộ phân biệt để bộ phân biệt học



Hình 1. Mô hình bộ khung DIGFuPAS

được cách phân loại lưu lượng. Từ đó, bộ phân biệt sẽ có khả năng đưa ra phản hồi về chất lượng dữ liệu mà bộ sinh tạo ra. Bộ sinh dựa vào phản hồi của bộ phân biệt để tự điều chỉnh và cải thiện khả năng sinh dữ liệu của mình. Chi tiết về luồng hoạt động của DIGFuPAS được trình bày trong **Hình 1**.

IDS hộp đen (B-IDS)

Nghiên cứu sử dụng B-IDS đóng vai trò như một hệ thống IDS sử dụng ngoài thực tế đang hoạt động tốt với các dữ liệu thông thường không có tính đối kháng. Đây là một hệ thống hộp đen với giả sử kẻ tấn công không có thông tin về cấu tạo và các thuật toán hoạt động bên trong của trình phân loại. Sau khi được huấn luyện, B-IDS phải có khả năng phát hiện các luồng lưu lượng độc hại khi có tấn công xảy ra. B-IDS nhận đầu vào là N thuộc tính thể hiện thông tin của luồng lưu lượng mạng và kết quả đầu ra dự đoán luồng lưu lượng là tấn công hay bình thường với độ chính xác cao. Chúng tôi hiện thực B-IDS sử dụng 5 thuật toán học máy là Logistic Regression (LR), Support Vector Machine (SVM), Gaussian Naive Bayes (NB), Decision Tree (DT) và Random Forest (RF).

Chúng tôi chọn ngưỡng tấn công là 0.5, vì vậy nhân dự đoán của B-IDS là 1 (tấn công) nếu $\sigma \geq 0.5$, ngược lại, nhân dự đoán là 0 (bình thường) nếu $\sigma < 0.5$.

Bảng 3. Thông số thiết kế bộ sinh

Lớp	Số lượng nơ-ron	Hàm kích hoạt
Input Layer	N-M (input_dim)	ReLU
Hidden Layers	input_dim//2	ReLU
	input_dim//2	ReLU
	input_dim//2	ReLU
	input_dim//2	Sigmoid
Output Layer	N-M	

Bộ sinh (Generator – G)

Bộ sinh có nhiệm vụ tạo ra dữ liệu đối kháng có khả năng qua mặt B-IDS. Trong N thuộc tính của luồng lưu lượng, chúng tôi tham khảo công trình SIGMA của nhóm tác giả Simon và cộng sự để chọn ra M thuộc tính đặc trưng (functional features) của cuộc tấn công cần phải được giữ lại (**Bảng 2**) [22]. Nếu M thuộc tính này bị thay đổi sẽ làm ảnh hưởng lớn đến tính chất của cuộc tấn công. Vì vậy, chúng tôi sử dụng bộ sinh để làm nhiễu N-M thuộc tính phi chức năng (nonfunctional-features) nhằm tạo ra dữ liệu đối kháng có khả năng qua mặt được IDS nhưng vẫn giữ được khả năng tấn công. Bộ sinh gồm 6 lớp mạng nơ-ron có thiết kế chi tiết như **Bảng 3**. Bộ sinh sẽ nhận đánh giá từ bộ phân biệt và điều chỉnh

Bảng 2. Thuộc tính đặc trưng từng loại tấn công

Loại tấn công	Thuộc tính đặc trưng (chức năng)
DOS	Flow Duration, Active Mean, Average Packet Size, Packet Length Std, Flow IAT Mean, PSH Flag Count, Idle Max
DDOS	Flow Duration, Bwd Packet Length Std, Average Packet Size, Packet Length Std, Flow IAT Std, ACK Flag Count
Bruteforce	PSH Flag Count, Flow Duration, Total Length of Fwd Packets, Init_Win_bytes_forward, Packet Length Std, Subflow Fwd Bytes, Fwd PSH Flags
Infiltration	Subflow Fwd Bytes, Total Length of Fwd Packets, Flow Duration, Idle Mean, Active Mean, Init_Win_bytes_backward, PSH Flag Count

trọng số để cải thiện khả năng sinh dữ liệu của mình. Hàm mất mát của bộ sinh (2) theo mô hình WGAN được định nghĩa là trung bình cộng điểm số đánh giá của bộ phân biệt cho dữ liệu được sinh ra từ bộ sinh.

$$L_G = E_{a \sim S_{ATTACK, noise}} D(G(a, noise)) \quad (2)$$

Bảng 4. Thông số thiết kế bộ phân biệt

Lớp	Số nơ-ron	Hàm kích hoạt
Input Layer	N-M (input_dim)	ReLU
Hidden Layers	input_dim*2	ReLU
	input_dim*2	ReLU
	input_dim*2	ReLU
	input_dim//2	Không sử dụng
Output Layer	N-M	

Bộ phân biệt (Discriminator – D)

Trong quá trình đào tạo, bộ phân biệt nhận dữ liệu đã được gán nhãn từ B-IDS và cố gắng học theo (bắt chước) cách hoạt động của B-IDS. Bộ phân biệt học cách đánh giá sự khác biệt giữa dữ liệu tấn công đối kháng và dữ liệu bình thường bằng thuật toán Wasserstein Distance. Chúng tôi sử dụng thiết kế cho bộ phân biệt như **Bảng 4**. Kết quả học của bộ phân biệt được dùng để đánh giá dữ liệu sinh ra từ bộ sinh và phản hồi lại cho bộ sinh giúp cải thiện khả năng sinh dữ liệu. Để tự cải thiện khả năng

phân biệt, hàm mất mát của bộ phân biệt (3) được định nghĩa là hiệu của trung bình cộng điểm số cho dữ liệu được gán nhãn tấn công với trung bình cộng điểm số cho dữ liệu được gán nhãn là bình thường.

$$L_D = E_{a \in B_{ATTACK}} D(a) - E_{n \in B_{NORMAL}} D(n) \quad (3)$$

C. Quá trình huấn luyện

IDS hộp đen sẽ được huấn luyện độc lập trước bằng tập dữ liệu train1. Sau quá trình huấn luyện, IDS hộp đen có khả năng phân biệt được lưu lượng là tấn công hay bình thường với độ chính xác cao. Tiếp đó, chúng tôi huấn luyện đồng thời bộ sinh và bộ phân biệt bằng tập dữ liệu train2. Bộ sinh sẽ nhận đầu vào là các thuộc tính phi đặc trưng của lưu lượng tấn công kèm theo nhiễu. Đầu ra của nó sẽ được ghép với các thuộc tính đặc trưng ban đầu được giữ lại tạo nên lưu lượng tấn công đối kháng hoàn chỉnh. Dữ liệu đối kháng tạo ra được trộn với các dữ liệu bình thường để đưa vào IDS hộp đen gán nhãn. Kết quả gán nhãn là đầu vào của bộ phân biệt, nhằm huấn luyện cho bộ phân biệt học cách đánh giá sự khác biệt giữa lưu lượng được B-IDS gán nhãn tấn công và bình thường. Bộ sinh sẽ gửi mẫu lưu lượng tạo ra cho bộ phân biệt đánh giá và sử dụng kết quả đánh giá của bộ phân biệt để cải thiện khả năng sinh dữ liệu của mình. Quá trình huấn luyện được xem như thành công khi có nhiều dữ liệu đối kháng tạo ra được IDS hộp đen gán nhãn là bình thường, có nghĩa là bộ sinh đã có khả năng sinh ra dữ liệu qua mặt được IDS hộp đen.

III. ĐÁNH GIÁ HIỆU NĂNG HỆ THỐNG

A. Phương pháp đánh giá

Chúng tôi thực hiện đánh giá kết quả của nghiên cứu dựa trên 2 tiêu chí là độ chính xác (Accuracy) và tỉ lệ phát hiện (Detection Rate - DR). Tuy nhiên, trong bài báo này, chúng tôi chỉ trình bày kết quả khảo sát tỉ lệ phát hiện được định nghĩa bằng **công thức (4)** đối với dữ liệu nguyên gốc (Original Detection Rate - ODR) và dữ liệu đối kháng (Adversarial Detection Rate - ADR).

Tỷ lệ phát hiện phản ánh tỷ lệ các bản ghi lưu lượng độc hại được phát hiện chính xác bởi IDS hộp đen trên tất cả các bản ghi được ghi nhận là tấn công. Việc khảo sát ODR và ADR cho thấy tương quan giữa khả năng phát

hiện của B-IDS và khả năng trốn tránh phát hiện của dữ liệu được tạo ra từ DIGFuPAS.

$$DR = \frac{TP}{TP+FP} * 100 \quad (4)$$

B. Môi trường thực nghiệm

Bộ khung DIGFuPAS được chúng tôi xây dựng và thử nghiệm trên hệ thống máy ảo chạy hệ điều hành Ubuntu 20.04 (Linux). Cấu hình phần cứng chi tiết sử dụng 16 nhân CPU Intel Xeon E5-2660 xung nhịp 2.0 Ghz, dung lượng RAM 16 GB, dung lượng ổ cứng 60 GB, hệ thống không được trang bị GPU. Mã nguồn của DIGFuPAS được lập trình bằng ngôn ngữ Python 3 sử dụng các thư viện chính như Numpy, Pandas, Scikit-learn, PyTorch và một số thư viện hỗ trợ khác.

IV. KẾT QUẢ

Trong phần này, chúng tôi thực hiện huấn luyện mô hình DIGFuPAS và sử dụng công thức (4) đã được trình bày ở phần III để kiểm chứng khả năng của mô hình.

Chúng tôi sử dụng thư viện Sklearn để xây dựng B-IDS vì các mô hình thuật toán đã được tích hợp sẵn và dễ sử dụng. Các mô hình được huấn luyện sử dụng giá trị mặc định của thư viện. Đối với bộ sinh và bộ phân biệt, chúng tôi sử dụng thư viện PyTorch để cho hiệu năng cao. Chúng tôi đã tham khảo các thông số được đề nghị cho mô hình WGAN và chọn tốc độ học 0.0005, batch size 512, thuật toán tối ưu RMSprop, bộ phân biệt được huấn luyện nhiều hơn bộ sinh gấp 5 lần, huấn luyện trong 50 chu kỳ. Sử dụng lưu lượng tấn công nguyên gốc (Original), lưu lượng bình thường từ tập dữ liệu kiểm thử và lưu lượng tấn công đối kháng (Adversarial) tạo ra từ lưu lượng tấn công nguyên gốc, chúng tôi thu được những kết quả như **Bảng 5**. Đối với tấn công DoS, chúng tôi thất bại trong việc tạo ra dữ liệu đối kháng qua mặt B-IDS sử dụng thuật toán Decision Tree khi không thể làm giảm tỉ lệ phát hiện. Nguyên nhân là do việc quyết định của cây phụ thuộc lớn vào các thuộc tính chức năng, trong khi thuật toán chỉ sinh dữ liệu đối kháng trên các thuộc tính phi chức năng. Tuy nhiên, nhìn chung mô hình đã cho kết quả khá tốt với B-IDS sử dụng các thuật toán khác, đặc biệt đánh lừa hoàn toàn B-IDS sử dụng thuật toán Random Forest. Với loại tấn công DDoS, dù tỉ lệ phát hiện tấn công nguyên gốc (ODR) rất cao nhưng

Bảng 5. Kết quả thử nghiệm về độ chính xác và tỉ lệ phát hiện

	DoS		DDoS		Bruteforce		Infiltration	
	ODR	ADR	ODR	ADR	ODR	ADR	ODR	ADR
LR	91.89	81.00	94.30	66.93	51.05	50.83	0	0
SVM	91.94	38.81	94.60	18.12	100	0	0	0
NB	89.71	31.94	94.00	0	13.44	0	0.45	0
DT	98.72	98.74	99.90	0	63.39	0.26	0	87.5
RF	99.76	0	99.60	0	98.49	0	0	0

bộ khung DIGFuPAS dễ dàng đánh lừa được tất cả các thuật toán B-IDS.

Với tấn công Bruteforce, tỉ lệ phát hiện tấn công nguyên gốc chưa đạt được kết quả tốt và biến động khá lớn tùy thuộc vào từng loại thuật toán. Nguyên nhân là vì quá trình tiền xử lý của chúng tôi còn đơn giản, chưa áp dụng việc lọc nhiễu dữ liệu dẫn đến kém chính xác. Do độ chính xác của các IDS không quá cao, mô hình DIGFuPAS không có đủ tham chiếu (nhân chính xác từ B-IDS) để huấn luyện nên trong một số trường hợp không cho kết quả tốt (trên thuật toán LR). Tuy vậy, mô hình vẫn đã thành công khi đã chứng minh được khả năng đánh lừa một số thuật toán ML B-IDS.

Loại tấn công Infiltration chưa thu được kết quả vì số lượng bản ghi tấn công quá ít, chỉ chiếm 36 trên tổng số 288602 bản ghi trong toàn bộ tệp dữ liệu nên mô hình coi đây là nhiễu và bỏ qua khi huấn luyện, do đó không thể phát hiện bất kỳ dữ liệu tấn công nào (cả loại dữ liệu tấn công ban đầu và loại dữ liệu đối kháng được sinh ra từ DIGFuPAS). Để khắc phục, chúng tôi dự kiến sẽ gộp một số kiểu tấn công khác có tính chất tương tự từ những tệp dữ liệu chưa được sử dụng trong bộ dữ liệu CICIDS2017 hoặc sử dụng dữ liệu được trích ra từ bộ dữ liệu mới CICIDS2018 nhằm tăng số mẫu tấn công dùng cho huấn luyện.

V. KẾT LUẬN

Với mục đích thường xuyên kiểm tra khả năng phát hiện của IDS, chúng tôi nghiên cứu phương pháp tạo ra các lưu lượng mạng tấn công đối kháng vượt qua hệ thống phát hiện xâm nhập từ đó triển khai thành bộ khung DIGFuPAS – một mô hình ứng dụng của Wasserstein GAN trong IDS. Kết quả đã cho thấy khả năng của DIGFuPAS trong việc tạo ra các mẫu lưu lượng đối kháng độc hại trước các loại tấn công khác nhau khi tỷ lệ phát hiện của các mô hình IDS hộp đen giảm xuống rất thấp. Từ đó, nghiên cứu này cho thấy được tính khả thi và tính linh hoạt của DIGFuPAS trong việc phát sinh ra các dữ liệu tấn công đối kháng đánh lừa khả năng nhận diện của IDS trên nhiều thuật toán học máy khác nhau. Trong tương lai, chúng tôi sẽ thử nghiệm DIGFuPAS trên nhiều loại tấn công khác nhau; tái huấn luyện IDS với đầu vào là tập dữ liệu lưu lượng đối kháng sinh ra; triển khai DIGFuPAS trên mạng khả lập trình như SDN (Software Defined Networking) dưới dạng chức năng mạng ảo hoá (Network Function Virtualization), áp dụng trong ngữ cảnh mạng Thành phố thông minh (Smart City).

LỜI CẢM ƠN

“Phan Thế Duy, VINIF.2020.TS.138 được tài trợ bởi Công ty CP thuộc Tập đoàn Vingroup và hỗ trợ bởi chương trình học bổng đào tạo thạc sĩ, tiến sĩ trong nước của Quỹ Đổi mới sáng tạo Vingroup (VINIF), Viện Nghiên cứu Dữ liệu lớn (VinBigdata)”.

TÀI LIỆU THAM KHẢO

- [1] C.-F. Tsai, Y.-F. Hsu, C.-Y. Lin and W.-Y. Lin, "Intrusion detection by machine learning: A review," *Expert Systems with Applications*, vol. 36, no. 10, p. 11994– 12000, 2009.
- [2] L. Zhipeng et al., "Intrusion Detection Using Convolutional Neural Networks for Representation Learning," in *24th International Conference (ICONIP 2017)*, 2017.
- [3] S. Z. Lin, Y. Shi and Z. Xue, "Character-level intrusion detection based on convolutional neural networks," in *International Joint Conference on Neural Networks (IJCNN)*, 2018.
- [4] N. a. W. D. Carlini, "Adversarial examples are not easily detected: Bypassing ten detection methods," *10th ACM Workshop on Artificial Intelligence and Security*, 2017.
- [5] I. Goodfellow et al., "Generative Adversarial Nets," *Advances in Neural Information Processing Systems*, 2014.
- [6] H. Lee, S. Han and J. Lee, "Generative Adversarial Trainer: Defense to Adversarial Perturbations with GAN," 2017.
- [7] C. Ledig et al., "Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network," in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [8] H.-W. Dong et al., "MuseGAN: Multi-track Sequential Generative Adversarial Networks for Symbolic Music Generation and Accompaniment," in *the Thirty-Second AAAI Conference on Artificial Intelligence*, New Orleans, 2018.
- [9] H. Su, X. Shen, P. Hu, W. Li and Y. Chen, "Dialogue Generation with GAN," in *The Thirty-Second AAAI Conference on Artificial Intelligence (AAAI-18)*, 2018.
- [10] J.-Y. Kim et al., "Malware Detection Using Deep Transferred Generative Adversarial Networks," in *International Conference on Neural Information Processing*, 2017.
- [11] W. Hu and Y. Tan, "Black-box attacks against mn based malware detection algorithms," *arXiv:1705.08131*, 2017.
- [12] M. Arjovsky et al., Wasserstein GAN, 2017.
- [13] K. Grosse et al., "Adversarial Perturbations Against Deep Neural Networks for Malware Classification," in *arXiv preprint arXiv:1606.04435*, 2016.
- [14] H. S. Anderson, A. Kharkar and B. Filar, "Evading machine learning malware detection," in *Black Hat*, 2017.
- [15] I. Rosenberg, A. Shabtai, L. Rokach and Y. Elovici, "Generic Black-Box End-to-End Attack Against State of the Art API Call Based Malware Classifiers," in *arXiv:1707.05970*, 2017.
- [16] A. Al-Dujaili, A. Huang, E. Hemberg and U.-M. O'Reilly, "Adversarial Deep Learning for Robust Detection of Binary Encoded Malware," in *arXiv:1801.02950*, 2018.
- [17] Y. Zhou, M. Kantarcioglu, B. Thuraisingham and B. Xi, "Adversarial support vector machine learning," in *Proceedings of the 18th ACM SIGKDD international conference on Knowledge discovery and data mining*, 2012.
- [18] J. Aiken and S. Scott-Hayward, "Investigating Adversarial Attacks against Network Intrusion Detection Systems in SDNs," in *NFV-SDN 2019*, Dallas, TX, USA, 2019.
- [19] W. Hu and Y. Tan, "Generating adversarial malware examples for black-box attacks based on GAN," *arXiv preprint arXiv:1702.05983*, 2017.
- [20] Lin, Zilong et al., "IDSGAN: Generative adversarial networks for attack generation against intrusion detection," *arXiv preprint arXiv:1809.02077*, 2018.
- [21] M. Usama et al., "Generative Adversarial Networks for Launching and Thwarting Adversarial Attacks on Network Intrusion Detection Systems," *IJWCMC 2019*, 2019.
- [22] S. Msika, A. Quintero and F. Khomh, "SIGMA: Strengthening IDS with GAN and Metaheuristics Attacks," *arXiv preprint arXiv:1912.09303*, 2019.